Lab 1：相关分析实验报告

练习 1–3：相关检验与随机置换

1　实验目的与总体设计

1.1　实验目的

本实验围绕相关性与独立性检验开展三项计算：比较非正态二元数据的 Pearson t 检验、正态近似 z 检验和置换检验；用随机置换逼近 Spearman 检验的精确 p 值；以逆序数构造 Kendall 型置换检验，并区分单侧与双侧的极端性条件。

1.2　实验环境与参数

采用 R 4.5.2，仅使用 R 自带函数。显著性水平统一取 $\alpha = 0.05$。为使计算可复现，指定随机数发生器为 Mersenne–Twister，并固定各阶段的随机种子。本报告的数值取自已运行的完整 R 脚本及其结果文件，未对模拟结果作筛选。

表 1：各练习的实验设置

实验	数据与置换次数	随机种子
练习 1	独立 Bernoulli 数据；$n = 20, 100, 1000$；每组 $N = 100000$	111、112
练习 2	讲义给定的 6 对数据；$N = 1000, 10000, 100000$	222
练习 3	同一组 6 对数据；$N = 100000$	333

其中，练习 1 先用种子 111 依次产生三组样本，再用种子 112 做置换，从而避免置换次数影响后续样本的生成。题目未指定练习 1 的样本量，因此选取三种规模进行比较。

1.3　置换检验与模拟精度

在独立性原假设下，固定一个变量并随机重排另一个变量，得到置换统计量 $T_1, \ldots, T_N$。对于以绝对值衡量极端性的双侧检验，按照讲义公式计算

$$\widehat{p} = \frac{1}{N} \sum_{b=1}^{N} \mathbf{1}\{|T_b| \geq |T_0|\}. \tag{1}$$

每次排列内部不放回，不同次排列之间允许重复；边界相等的情况计入极端次数。本文使用讲义要求的“极端次数除以 N”，并用

$$\mathrm{MCSE} = \sqrt{\frac{\widehat{p}(1-\widehat{p})}{N}} \tag{2}$$

评估固定当前样本时的蒙特卡洛误差。随机置换给出的是精确置换概率的**模拟估计**。对仅有 6 个观测的练习 2、3，另穷举全部 $6! = 720$ 个排列，并与 R 内置精确检验核对。

1.4　结果与复现文件

完整代码为 `lab1_exercises_1_3.R`，运行记录为 `lab1_results/results.txt`，三个练习的数值表分别保存在 `lab1_results/exercise1.csv` 至 `exercise3.csv`。

2　练习 1：二元非正态数据的三种检验

2.1　数据生成与检验方法

独立产生 n 对观测 (X_i, Y_i)，其中 $X_i \sim \text{Bernoulli}(0.3)$、$Y_i \sim \text{Bernoulli}(0.6)$，且 $X_i \perp Y_i$，各观测对之间独立。对每组相同数据计算 Pearson 样本相关系数 r，再比较以下三种双侧检验：

$$t = \frac{\sqrt{n-2}\,r}{\sqrt{1-r^2}}, \qquad p_t = 2\Pr(t_{n-2} \geq |t|), \tag{3}$$

$$z = \sqrt{n-2}\,r, \qquad p_z = 2\Phi(-|z|). \tag{4}$$

t 检验由 `cor.test` 计算；z 检验按讲义使用 $\sqrt{n-2}$。由于总体非正态，t_{n-2} 不再是该统计量的精确零假设分布；在本题的独立 Bernoulli 总体下，z 检验为大样本近似。

置换检验固定 y、重排 x，每组执行 100000 次。计算时使用与 r 成正比的统计量

$$T = n\sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right). \tag{5}$$

置换不改变相关系数的分母，故比较 $|T_b| \geq |T_0|$ 完全等价。这里 T 为整数，可避免极端性边界的浮点舍入误差。

2.2　实验结果与精确核对

表 2: 三种检验的双侧 p 值

n	r	t 检验	z 检验	置换检验
20	-0.104828	0.660056	0.656501	1.00000
100	-0.024323	0.810168	0.809720	0.83057
1000	-0.025198	0.426052	0.426009	0.46642

对二元数据，固定边际和 $s_x = \sum_i x_i$、$s_y = \sum_i y_i$ 后，$K = \sum_i x_{\pi(i)} y_i$ 服从总体大小为 n、成功数为 s_x、抽取数为 s_y 的超几何分布。将满足 $|nK - s_x s_y| \geq |T_0|$ 的概率相加，得到下表的精确参考值。

表 3: 随机置换估计与同一统计量的精确置换结果

n	极端次数	精确置换 p 值	模拟标准误
20	100000	1.000000	0.000000
100	83057	0.830965	0.001186
1000	46642	0.465930	0.001578

2.3　分析与结论

t 与 z 检验结果接近，但离散性使其与置换检验存在差异。$n = 20$ 时，$s_x = 2$、$s_y = 13$、$\sum_i x_i y_i = 1$，因而 $T_0 = -6$；置换后的 K 只能为 $0, 1, 2$，对应 $T = -26, -6, 14$。所有排列均满足 $|T| \geq 6$，所以精确 p 值就是 1，模拟标准误为 0；这不表示相关系数本身没有抽样误差。

较大样本下连续近似通常改善，但有限样本的离散效应仍可能存在，差异不要求随 n 单调减小。本次所有 p 值均大于 0.05，未拒绝各自的原假设。“未拒绝”不能证明独立；一般情况下，Pearson 不相关也不等价于独立。

3　练习 2：Spearman 检验的置换逼近

3.1　原始数据与统计量

采用讲义中的数据

$$x = (-11, -2, 5, 6, 8, 9), \qquad y = (-3, 2, 4, 1, 12, 5).$$

其秩分别为 $R = (1, 2, 3, 4, 5, 6)$ 和 $S = (1, 3, 4, 2, 6, 5)$。因此

$$\rho_s = \mathrm{cor}(R, S) = 0.7714286. \tag{6}$$

在独立性原假设下，固定 S、随机置换 R，并按照双侧极端性条件计算

$$\widehat{p}_N = \frac{1}{N} \sum_{b=1}^{N} \mathbf{1}\{|\rho_s^{(b)}| \geq |\rho_s|\}. \tag{7}$$

分别执行 $N = 1000, 10000, 100000$ 次置换。三个规模各自执行指定次数，共同使用从种子 222 开始的随机数序列。

3.2　置换结果与精确分布

表 4: Spearman 双侧置换检验结果

N	极端次数	置换 p 值	模拟标准误	绝对误差
1000	116	0.11600	0.010126	0.013222
10000	1013	0.10130	0.003017	0.001478
100000	10161	0.10161	0.000955	0.001168

由于本组数据没有相同秩，全部排列共有 $6! = 720$ 个，其中 74 个满足双侧极端性条件。由此得到

$$p_{\mathrm{exact}} = \frac{74}{720} = 0.1027778 \approx 0.1028. \tag{8}$$

该结果与讲义及 R 的 `cor.test(x,y,method="spearman",exact=TRUE)` 一致。表中的绝对误差为 $|\widehat{p}_N - p_{\mathrm{exact}}|$。

3.3　核心实现

秩的均值与平方离差和不随排列改变，因此可以用整数分子来判断极端性。以下代码展示完整脚本中的主要计算方式：

```
set.seed(222)
rx <- rank(x); ry <- rank(y); n <- length(x)
offset <- sum(rx) * sum(ry)
S0 <- n * sum(rx * ry) - offset
for (N in c(1000L, 10000L, 100000L)) {
  Sp <- replicate(N, n * sum(rx[sample.int(n)] * ry) - offset)
  print(c(N = N, p = mean(abs(Sp) >= abs(S0))))
}
```

3.4　分析与结论

三种置换次数得到的 p 值均在精确值 0.1028 附近。置换次数增大时，模拟标准误按 $N^{-1/2}$ 的量级下降；例如由 1000 次增加到 100000 次，标准误从约 0.0101 降到约 0.0010。本次误差随次数增加而减小，但随机模拟的单次误差不保证单调下降。

置换结果验证了随机置换对精确 p 值的逼近。在 $\alpha = 0.05$ 水平下，不能拒绝独立性原假设。样本秩相关系数虽为正且数值较大，但仅凭这 6 对数据，尚不足以得出统计显著的关联结论。

4　练习 3：基于逆序数的置换检验

4.1　逆序数与 Kendall 系数

按 x 从小到大排列后，$y = (-3, 2, 4, 1, 12, 5)$。定义

$$D = \sum_{1 \le i < j \le n} \mathbf{1}(y_i > y_j). \tag{9}$$

逆序对的下标为 $(2,4)$、$(3,4)$、$(5,6)$，故 $D_0 = 3$。共有 $M = \binom{6}{2} = 15$ 对，因此 Kendall 系数为 $\tau_0 = (M - 2D_0)/M = 0.6$。

4.2　检验方向与置换方法

题目强调“D 越小，正相依性越强”，故首先考虑正相关的单侧备择。在独立性原假设下固定 x、随机重排 y，每次重新计算 D_b，得到

$$\widehat{p}_{\text{one}} = \frac{1}{N} \sum_{b=1}^{N} \mathbf{1}(D_b \le 3). \tag{10}$$

若检验任一方向的关联，则以 $M/2 = 7.5$ 为中心衡量极端性，条件等价于 $|\tau_b| \ge |\tau_0|$，即

$$\widehat{p}_{\text{two}} = \frac{1}{N} \sum_{b=1}^{N} \mathbf{1}(D_b \le 3 \text{ 或 } D_b \ge 12). \tag{11}$$

由于 D 非负且不以零为中心，不能直接用 $|D_b| \ge |D_0|$ 作为双侧极端性条件。

4.3　实验结果

采用种子 333，执行 $N = 100000$ 次置换。两个方向的结果由同一组置换统计量计算。

表 5: 逆序数置换检验与精确结果

方向	极端次数	置换 p 值	模拟标准误	精确 p 值
正相关单侧	6728	0.06728	0.000792	$49/720 = 0.068056$
双侧	13565	0.13565	0.001083	$98/720 = 0.136111$

穷举 720 个排列后，单侧与双侧极端排列数分别为 49 和 98。精确结果与 R 内置 Kendall 检验的 `alternative="greater"` 及 `alternative="two.sided"` 分别一致。

4.4　核心实现

```
set.seed(333)
ys <- y[order(x)]; pairs <- combn(seq_along(ys), 2L)
inversions <- function(v) sum(v[pairs[1L, ]] > v[pairs[2L, ]])
Dp <- replicate(100000L, inversions(ys[sample.int(length(ys))]))
p_one <- mean(Dp <= 3)
p_two <- mean(Dp <= 3 | Dp >= 12)
```

4.5　分析与实验总结

按“小逆序数对应正相依”的单侧设定，所求精确 p 值约为 **0.0681**，本次置换估计为 **0.06728**；双侧精确值约为 **0.1361**。两种设定在 0.05 水平下均不显著。

三项实验表明：有限样本中应注意连续近似与离散置换分布的差异；增加置换次数可降低模拟误差；构造置换检验时必须根据备择假设选择正确的尾部。Spearman 与 Kendall 描述不同的秩关联特征，未检出显著性也不能据此断言总体独立。